不可靠病历下临床智能体的动作安全研究报告

本项目将两页计划书落实为可运行的研究框架、源码反例、实验协议和英文论文初稿。现阶段能够确认的是评分机制及执行抽象中的问题，尚不能确认任何大模型的故障发生率或缓解效果。离线演示来自明确标记的合成病例与编程基线；新增 CPU 模型与订阅推理实测见《双路径实测报告》。

研究问题与贡献边界

研究的核心是区分三件事：智能体是否忠实遵循当前病历；其动作是否符合预先声明的策略或干净参考；原评分器是否会接受该动作。三者可能同时出现分歧。例如，干净的镁值为 1.8 mg/dL，按基准规则应提出 1 g、1 小时的医嘱；将数值改为 0.18 后，同一规则会产生 4 g、4 小时的医嘱。如果评分器也读取 0.18，该错误参考可以接受 4 g 的动作。

这个例子支持“评分器可能接受由故障数据驱动的参考偏离”。它不证明真实模型一定会执行这种动作，也不等同于四倍临床伤害。本文所有剂量规则都来自 benchmark 的简化任务，而不是完整临床治疗方案。

建议将论文贡献表述为：共享病历状态导致的评分耦合；可观察证据缺陷与不可观察参考偏离的双重评价；独立参考与已提交动作的配对评分；证据核验提示的效益和正常任务成本。不要将“首个临床智能体评分器审计”作为贡献，因为已有直接相关工作。

已完成的源码核验

原仓库固定在提交 `99260117137b09f04837a8c18d18a1107efa55ae`。原始 `refsol.py` 从作者 README 指向的 Box 链接下载，SHA-1 为 `1440e8b982059a3fc730a26f448465f549910b36`，与公开页面记录一致。项目保存未修改的文件；审计运行时只替换网络读取，以便向原评分函数提供受控病历快照。

现象	实际复现	对计划书的影响
评分器读取当前病历	同一条 4 g 医嘱在 0.18 病历上通过、在 1.8 病历上失败	支持评分耦合问题，属于确定性反例
v1 的 POST 抽象	原 runner 解析 JSON 后返回成功，没有发送 HTTP POST	原基准成绩表示接受的动作提案，不能称数据库已执行
POST 子串检测	“I will not POST an order”被识别为存在 POST	是动作检测误差，通常造成错误拒分，不能说它产生了医嘱
最后一条消息越界	提及 POST 的末尾消息可使提取器抛出 IndexError	评分器异常需独立保留，不能悄悄合并为普通失败
钾检验没有年龄限制	500 天前的 3.0 仍可按规则通过补钾及复查医嘱	原 task9 也没有时间窗，这属于规则选择，不是确定的实现缺陷
镁的未来日期	未来 30 天的记录仍满足原评分器的下界过滤	扩展策略明确拒绝未来证据，原评分结果保留作对照
缺失 HbA1c 的分支	原评分器要求新检验；任务明确要求返回 [-1]，但只明确为过期结果要求新检验	主策略采用任务字面解释，原评分结果作为语义敏感性对照
route 格式冲突	工具定义给出对象 route，评分器要求裸字符串 IV	属于格式问题，不能误写为剂量推理失败

上述结果保存在 `results/audit.json`。这些审计均未调用 LLM。公开原论文也说明 POST 仅作 JSON 检查，因此应将其称为基准执行抽象，而不是将没有真实写入作为新发现。

对原研究设计的必要修订

独立参考需要区分可观察与不可观察错误

当记录缺失、超出明确时窗、具有未知单位、来自未来或在同一时间互相矛盾时，智能体可以根据可见证据判断应当暂缓。当故障把一个值变成另一个仍合理的值，并且没有额外可信来源时，干净值对模型不可识别。仅要求其引用病历，不能恢复看不到的真值。

因此，分别报告“ 可观察策略违反 ”和“ 相对干净参考的动作偏离 ”。原计划的 `faithful_unsafe` 标签保留为研究策略下的标签，但其含义由这两个字段进一步解释。不能将所有参考偏离都归因于模型缺乏可实现的安全推理。

HbA1c 的过期规则优先

如果当前可见的 HbA1c 已超过一年，任务明确要求新检验，不能因为干净病历中的结果较新，就将这次正确补查判为危险行为。框架允许这一任务特例，同时单独记录相对干净参考增加的检验。

缺失 HbA1c 时，主策略返回 [-1] 并暂缓。原始评分器要求新检验，两种语义并列保存，不混在一个正确率里。HbA1c 的数值和时间回答也被独立检查；医嘱正确不代表整个任务已完成。

单位故障的适用范围

0.4114 是本计划中镁的近似换算因子。将它乘到钾、血糖或 HbA1c 上并保持单位标签不变，不能统称为相同的单位换算错误。核心实验只在 task4、task5 的 mg/dL 镁记录上施加此故障。其他任务标为结构上不适用。源记录不是 mg/dL 时也应另记不适用。

模型比较减少家族混杂

原计划的 8B、32B、70B 很容易来自不同家族。默认改为同系列 Qwen2.5 Instruct 的 7B、32B、72B，统一 AWQ 4-bit 格式并锁定版本。仍须把结果解释为特定模型间的规模相关差异，而不是“ 只有参数规模发生变化 ”的因果实验。

干预与策略信息分开

两个实验臂获得相同的研究策略、检验时间窗和数字边界，拥有相同回合预算与工具。干预臂仅增加逐次写入前的检索、引用和核验流程。如果只告诉干预组策略要求，会把新增知识与流程效果混淆。

已交付的软件能力

框架只使用 Python 标准库，包含四种故障和干净对照、完整历史重选、不可变快照校验、每轮独立 SQLite 库、真实本地提交与读回、原评分器与独立评分器、模型端点客户端、严格配对的患者聚类 bootstrap、逐条运行文件和按配置恢复运行。

每条记录保存输入和策略哈希、故障前后对象、工具请求、已提交资源、回复、原评分结果、独立标签、时间与 token 用量。恢复运行的身份包含代码、完整配置和快照指纹；改变策略或代码会产生新的运行身份。错误后的已提交医嘱仍会接受安全评分，不能因 API 断开或没有 FINISH 就被忽略。

只读导出器支持 FHIR Bundle 翻页，并保存资源历史与校验文件。正式评估使用这些历史的本地缓存，并保留 benchmark 的简化资源表达，不能声称获得了真实 FHIR R4 服务上的执行结果。完整外部 EHR 写入及恢复适配器属于后续独立验证层。

当前验证结果

2026-11-05 的中期补充实验在同一份已授权两例输入上冻结新的统一格式协议：两提示臂均使用一致的 route 字符串 schema 和明确的 FINISH 回答形式。6 次新采样全部完成、全部通过原评分器，其中 2 次镁单位故障偏离独立干净参考；同一原始轨迹在干净病历下被原评分器拒绝。未修改剂量规则或评分器，也未事后规范化输出。这是先导机制证据，两个故障运行来自同一个镁病例。另对全部 30 条 Codex 轨迹移除数值边界进行重评分，4 条暂缓标签发生改变，不安全动作判定未变。54 项回归测试通过。详见《中期报告说明》及四页 NeurIPS 英文稿。

2026-10-31，用户明确授权的两例最小化原基准输入完成 6 次适用 Codex 运行，另外 2 次钾单位故障按预设标为不适用。4 次干净条件的医嘱符合独立参考；2 次镁单位故障中，普通提示和证据提示均提交 4 g/4 h，干净参考为 1 g/1 h。证据提示引用的数值、单位和时间与检索内容一致，故这一先导支持“引用当前记录不能揭示缺乏独立证据的隐蔽损坏”的具体机制，不能估计总体发生率或干预效果。

6 条轨迹的原评分均未通过，全部存在 route 对象与原评分器要求裸字符串的冲突，最终回复也不符合其数值列表或空列表约束。原始结果没有经过格式修正，不能把独立评分的 4 次正确当作原评分器通过。详细记录、25 个推理回合的使用量、授权范围和每轮恢复校验见《双路径实测报告》及 `results/pilot-original-codex/verification.json`。本次报告检查不替代预定双人盲审。

已完成源码反例及自动测试，覆盖剂量边界、时间窗边界、单位归一、未知单位、并发冲突、有效替代记录、重复医嘱、错误患者、警告后仍写入、提交后中断、配对缺失、患者聚类、校验文件和模型 HTTP 请求协议。最终测试数量及日志见交付根目录的验证记录。

合成演示使用 30 个病例，3 个编程控制策略，5 个条件。450 个名义组合中 54 个不适用，396 个有效运行。它检验软件路径，不为真实临床记录或大模型提供性能证据。

选出的真实任务各类别 30 个，共 150 个任务，涉及 87 位患者。两个用药类别合计 60 个任务，涉及 54 位患者。这是任务清单的直接统计，不是运行过真实病历后的结果。

仍需真实资源完成的工作

首先启动原 MedAgentBench 镜像，记录镜像摘要，导出完整的基准病历，检查单位、时间、缺失分支和原始参考是否可解释。随后使用原 harness、全部 300 个任务进行独立的历史结果复现；原论文 GPT-4o-mini 的总体成功率为 56.33%，这个数字不能直接用于 150 个任务子集或扩展 harness。MedAgentBench 原论文

在真实快照通过预检后，以小规模先导实验测量上下文长度、回合数、推理速度和无效格式比例，再完成三模型、两实验臂的主体实验。对异常解释进行双人盲审，对没有数值边界的策略重新评分或重跑，并将统计结果填入论文的预先定义表格。

目前已取得全部 150 个任务的相关病历快照，部署 CPU 小模型并完成有限的订阅推理测试；主体三模型实验、临床领域策略审阅和人工解释标注仍待完成。因此论文具备审计、数据剖析与先导实验初稿，尚不能作为已完成主体模型比较的实证论文提交。